

# Análisis de Relaciones entre Variables

## Tablas cruzadas, covarianza, correlación y visualización


Mag. Sadan De la Cruz Almanza

# Objetivos de aprendizaje

- Distinguir relaciones entre variables categóricas y numéricas.
- Construir e interpretar tablas de contingencia.
- Comprender covarianza y correlación como medidas de asociación.
- Visualizar relaciones bivariadas mediante diagramas de dispersión.
- Reconocer límites metodológicos: independencia, escala, linealidad y atípicos.

- 1 Tablas de frecuencia cruzadas.
- 2 Matriz de covarianza.
- 3 Matriz de correlación.
- 4 Gráficas de relaciones entre variables.

# Mapa conceptual



# Tablas de contingencia: sentido estadístico

## Definición

Una tabla de frecuencia cruzada resume la distribución conjunta de dos o más variables categóricas.

- Organiza conteos por combinaciones de categorías.
- Permite comparar perfiles de grupos.
- Sirve como punto de partida para estudiar independencia estadística.

## Frecuencia relativa conjunta

$$P(A \cap B) = \frac{n_{ij}}{N}$$

- $n_{ij}$ : conteo observado en la celda de la fila  $i$  y columna  $j$ .
- $N$ : total de observaciones.
- La proporción conjunta interpreta qué fracción del total pertenece simultáneamente a dos categorías.

## Frecuencia esperada bajo independencia

$$E_{ij} = \frac{n_{i.} \times n_{.j}}{N}$$

- $n_{i.}$ : total marginal de la fila  $i$ .
- $n_{.j}$ : total marginal de la columna  $j$ .
- Compara lo observado con lo que se esperaría si las variables fueran independientes.

## Ejemplo aplicado: PDET y bibliotecas

- Variable 1: estatus PDET del municipio (Sí/No).
- Variable 2: nivel de adopción o uso de bibliotecas públicas (Alto/Medio/Bajo).
- Pregunta analítica: ¿la distribución del uso de bibliotecas cambia entre municipios PDET y no PDET?



## Código en R: tabla cruzada

```
municipios <- data.frame(  
  PDET = sample(c("Si", "No"), 100, replace = TRUE),  
  Uso_Biblioteca = sample(c("Alto", "Medio", "Bajo"),  
                           100, replace = TRUE)  
)  
  
tabla_cruzada <- table(municipios$PDET,  
                      municipios$Uso_Biblioteca)  
print(tabla_cruzada)  
  
round(prop.table(tabla_cruzada, margin = 1), 2)
```

# Matriz de covarianza

## Idea central

La covarianza cuantifica la variabilidad conjunta entre dos variables numéricas.

- Valor positivo: relación directa.
- Valor negativo: relación inversa.
- Valor cercano a cero: ausencia de asociación lineal fuerte.
- Su magnitud depende de las unidades de medición.

# Covarianza muestral

$$\text{Cov}(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n - 1}$$

- Evalúa si las desviaciones respecto a sus medias se mueven juntas.
- No está acotada, por lo que su interpretación aislada puede ser difícil.
- Es el insumo conceptual de la correlación.

## Ejemplo aplicado: IPM y encomiendas

- Variable  $X$ : Índice de Pobreza Multidimensional (IPM).
- Variable  $Y$ : número histórico de encomiendas coloniales por municipio.
- Interés analítico: explorar si territorios con mayor carga histórica muestran patrones distintos de pobreza contemporánea.

## Código en R: matriz de covarianza

```
datos_cov <- data.frame(  
  IPM = rnorm(50, mean = 40, sd = 10),  
  Encomiendas = rnorm(50, mean = 5, sd = 2)  
)  
  
matriz_cov <- cov(datos_cov)  
print(matriz_cov)
```

# Matriz de correlación

## Definición

La correlación es una versión estandarizada de la covarianza que mide fuerza y dirección de la relación lineal.

- Está acotada en  $[-1, 1]$ .
- 1: relación lineal positiva perfecta.
- $-1$ : relación lineal negativa perfecta.
- 0: ausencia de relación lineal, no necesariamente ausencia total de relación.

# Coeficiente de Pearson

$$r = \frac{\text{Cov}(X, Y)}{S_x S_y}$$

- $S_x$  y  $S_y$  son las desviaciones estándar muestrales.
- La estandarización permite comparar relaciones entre variables con unidades distintas.
- Su lectura debe acompañarse de visualización y criterio sustantivo.

## Escala interpretativa de $r$

| Valor aproximado | Interpretación                       |
|------------------|--------------------------------------|
| $r \approx 1$    | Asociación lineal positiva fuerte    |
| $r \approx -1$   | Asociación lineal negativa fuerte    |
| $r \approx 0$    | Asociación lineal débil o nula       |
| $0 < r < 1$      | Aumentan juntas en distinto grado    |
| $-1 < r < 0$     | Una aumenta cuando la otra disminuye |



## Ejemplo aplicado: Catatumbo

- Variables: IPM, inversión en Obras por Impuestos y cobertura en salud.
- Pregunta orientadora: ¿qué tan alineadas están las condiciones sociales, la inversión y la cobertura institucional?
- La matriz de correlación permite detectar pares de variables que merecen análisis posterior.

## Código en R: matriz de correlación

```
datos_cor <- data.frame(  
  IPM = rnorm(50, 60, 15),  
  Inversion_0xI = rnorm(50, 1000, 300),  
  Cobertura_Salud = rnorm(50, 70, 10)  
)  
  
matriz_cor <- cor(datos_cor)  
print(matriz_cor)
```

# Visualización rápida de correlaciones

```
library(corrplot)

corrplot(matriz_cor, method = "circle")
```

- El tamaño y color de los círculos resumen intensidad y dirección.
- Es útil para matrices con muchas variables.

# Diagrama de dispersión

## Herramienta fundamental

El scatterplot permite visualizar relaciones bivariadas continuas antes de resumirlas con un coeficiente.

- Revela patrones lineales y no lineales.
- Muestra agrupaciones o clusters.
- Ayuda a detectar valores atípicos.
- Permite evaluar si Pearson es una síntesis razonable.

## Ejemplo aplicado: pobreza y violencia

- Variable explicativa visual: Índice de Pobreza Multidimensional.
- Variable de respuesta visual: índice de violencia armada.
- La línea de tendencia permite resumir la dirección promedio de la asociación.
- La nube de puntos revela dispersión y casos divergentes.

## Código en R: dispersión con tendencia

```
library(ggplot2)

datos_graf <- data.frame(
  IPM = runif(100, 20, 80),
  Violencia = runif(100, 0, 50)
)

datos_graf$Violencia <- datos_graf$Violencia +
  0.5 * datos_graf$IPM

ggplot(datos_graf, aes(x = IPM, y = Violencia)) +
  geom_point(color = "steelblue", alpha = 0.7) +
  geom_smooth(method = "lm", color = "darkred", se = TRUE) +
  theme_minimal()
```

# Buenas prácticas de interpretación

- Asociación no implica causalidad.
- Una correlación baja no descarta relaciones no lineales.
- Los outliers pueden modificar fuertemente la pendiente y el coeficiente.
- La lectura estadística debe dialogar con teoría, territorio y calidad del dato.

## Cierre de la clase

- Las tablas cruzadas describen relaciones entre variables categóricas.
- La covarianza expresa movimiento conjunto, pero depende de unidades.
- La correlación estandariza la asociación lineal y facilita comparación.
- La visualización es indispensable para evitar interpretaciones mecánicas.